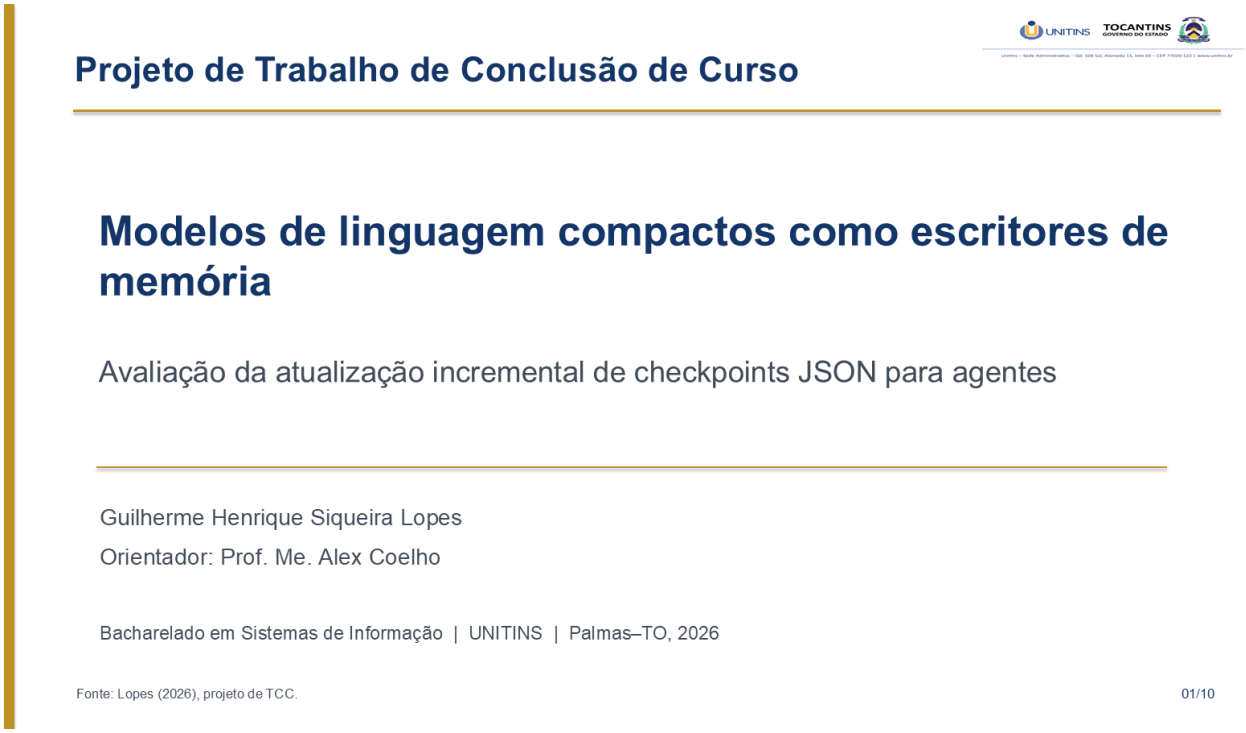
Roteiro de apresentação

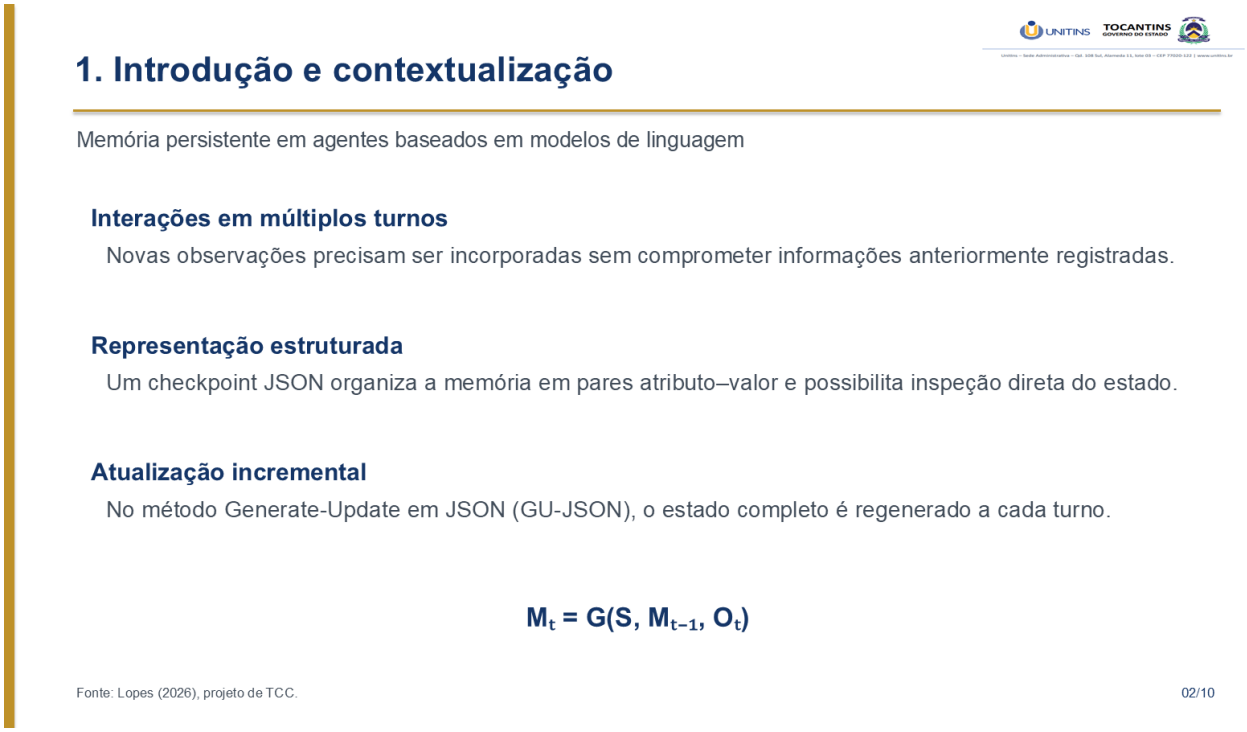
Modelos de linguagem compactos como escritores de memória · Meta: 3 minutos

Slide 1 — até 0:10



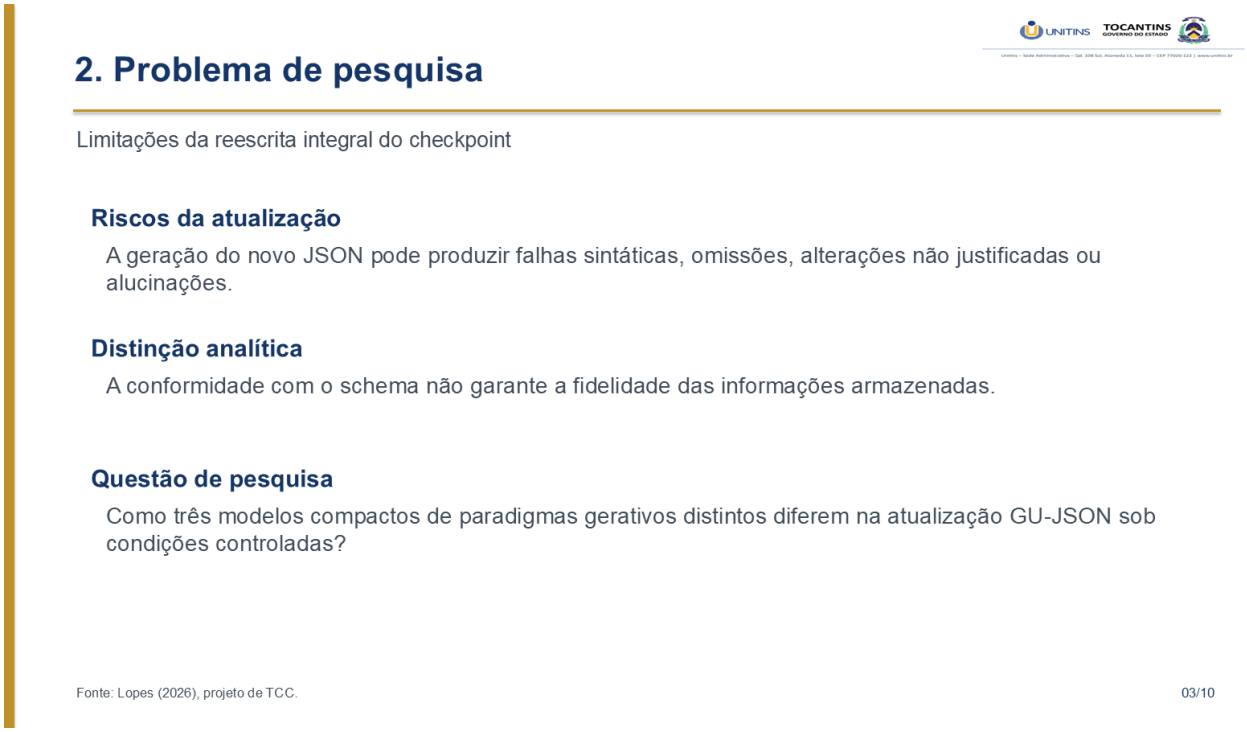
Bom dia. Sou o Guilherme Lopes e vou apresentar meu projeto de TCC: modelos de linguagem compactos como escritores de memória, avaliando a atualização incremental de checkpoints JSON para agentes.

Slide 2 — até 0:30



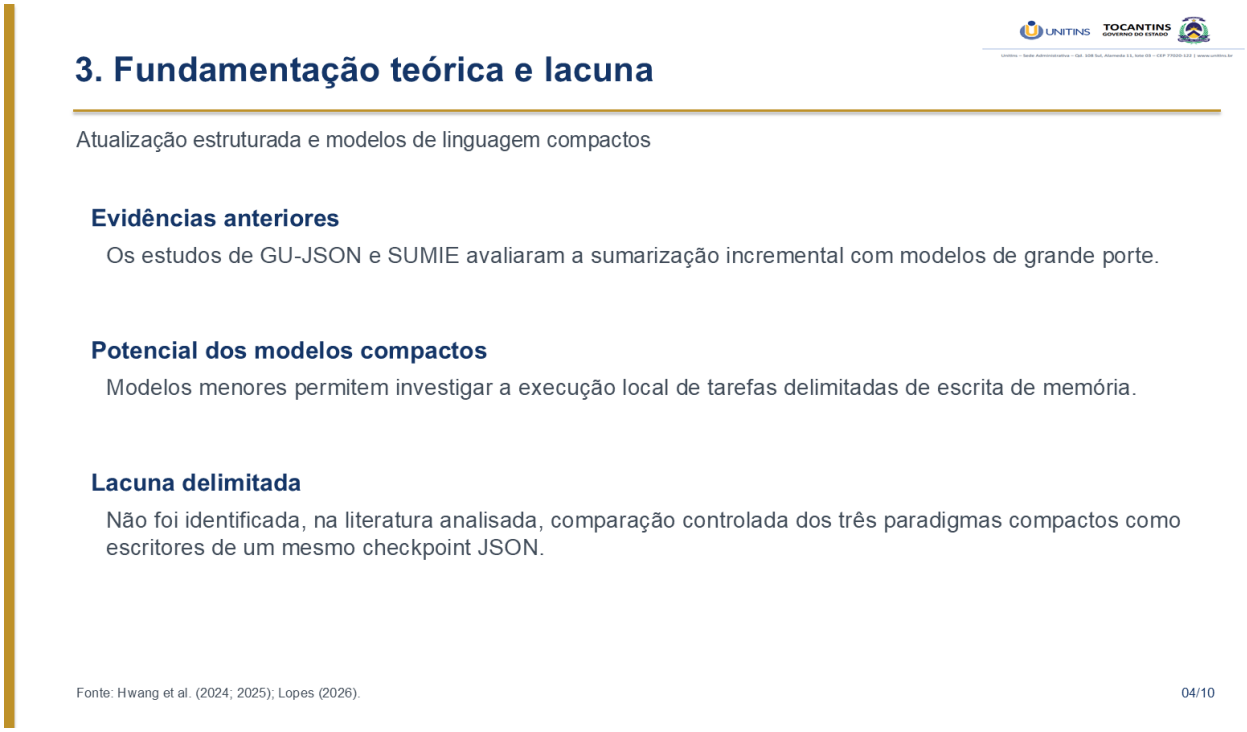
Agentes baseados em modelos de linguagem trabalham em vários turnos e recebem informações novas a cada etapa. Colocar todo o histórico no contexto é caro e pode estourar a janela. Uma alternativa é guardar a memória em um checkpoint JSON, com pares atributo–valor. No método GU-JSON, a cada turno o modelo recebe o estado anterior e a nova observação e reescreve o JSON completo.

Slide 3 — até 0:48



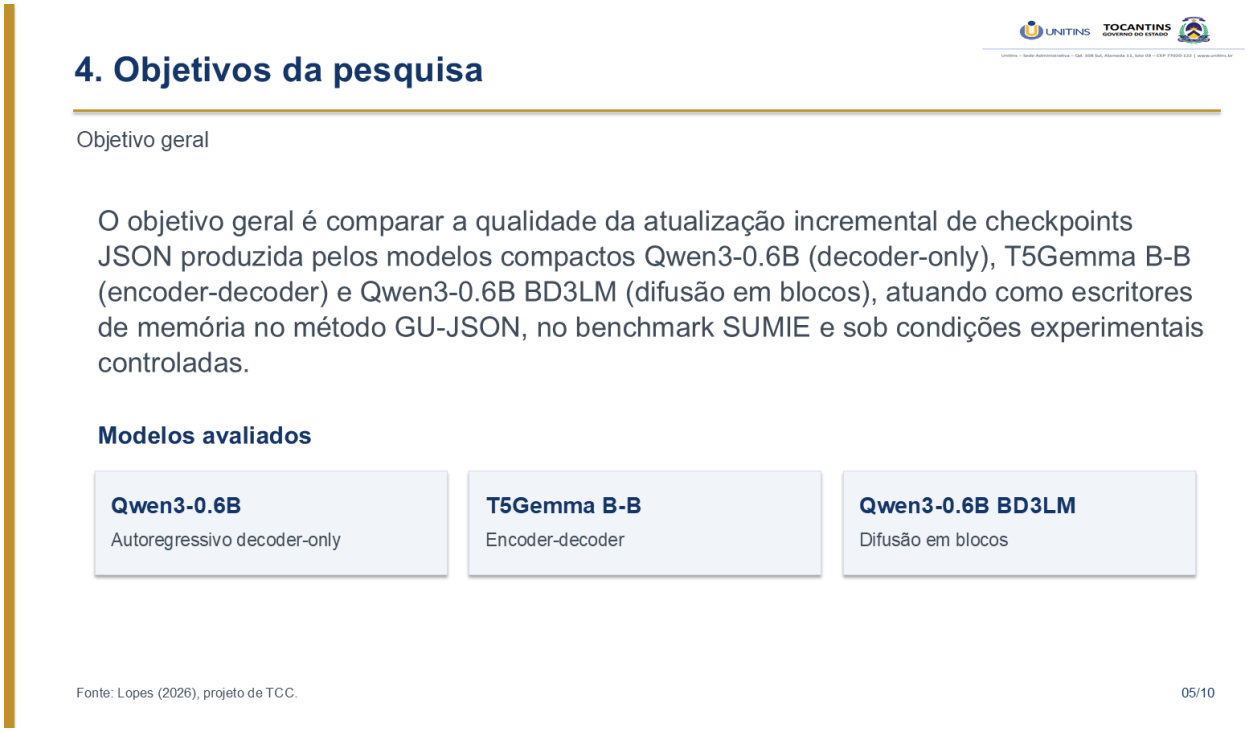
O problema é que essa reescrita pode falhar. O JSON pode sair quebrado, fatos válidos podem ser omitidos ou alterados, e o modelo pode inventar informações. Além disso, um JSON bem formatado não garante que o conteúdo esteja correto.

Slide 4 — até 1:03



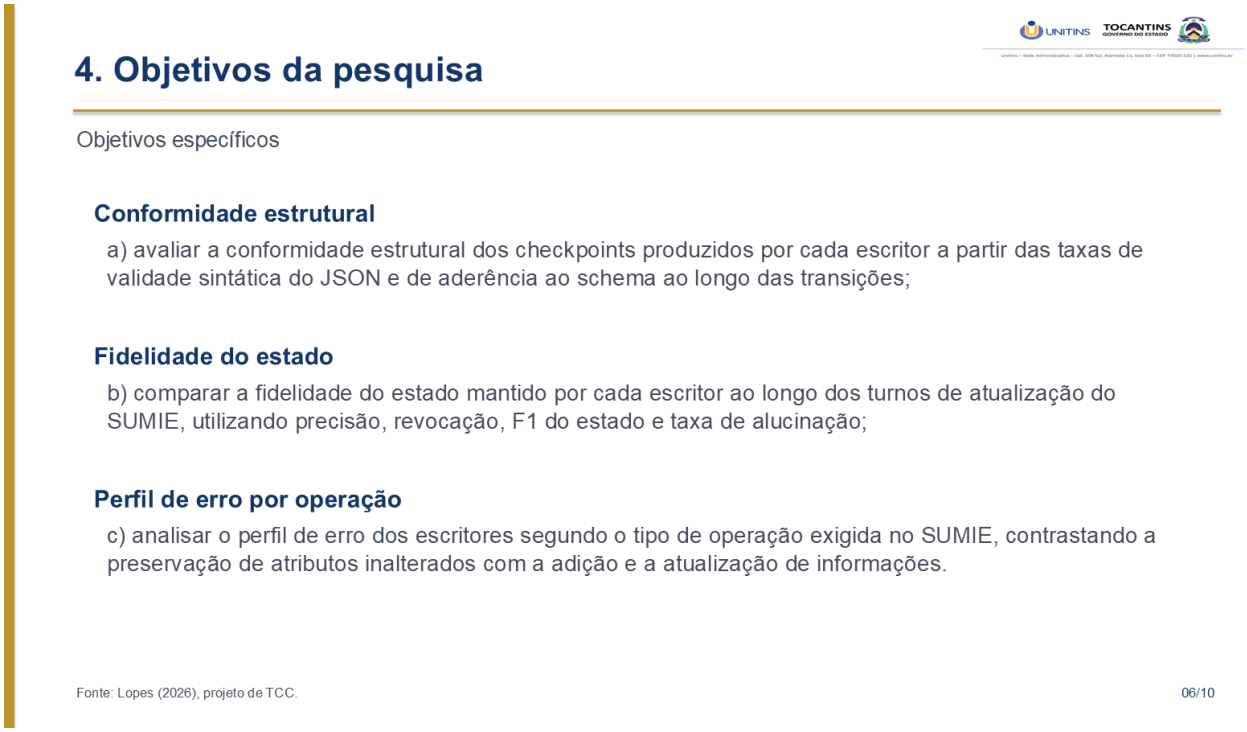
O GU-JSON e o benchmark SUMIE foram avaliados com modelos de grande porte. Na literatura que analisei, não encontrei uma comparação controlada entre modelos compactos de paradigmas diferentes realizando essa tarefa.

Slide 5 — até 1:20



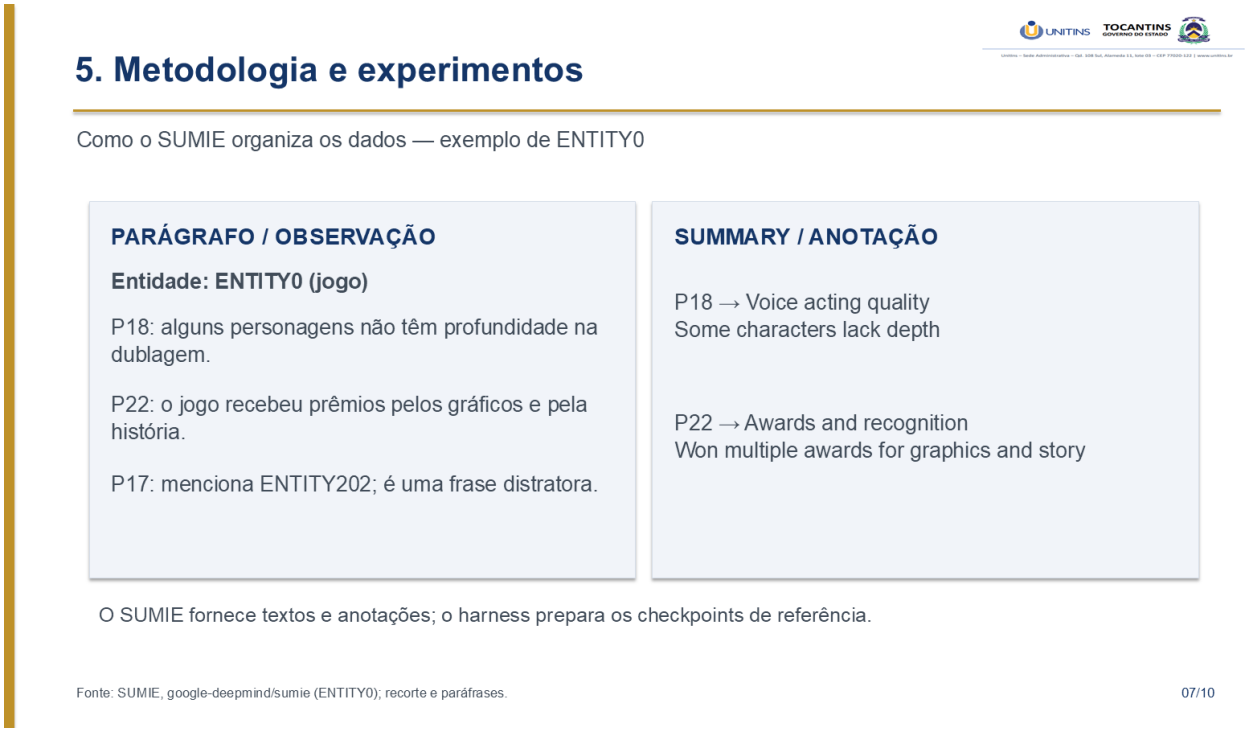
Por isso, o objetivo geral é comparar três modelos de cerca de 0,6 bilhão de parâmetros: o Qwen3, autoregressivo decoder-only; o T5Gemma, encoder-decoder; e o Qwen3 BD3LM, de difusão em blocos. Todos vão atuar como escritores de memória no SUMIE.

Slide 6 — até 1:38



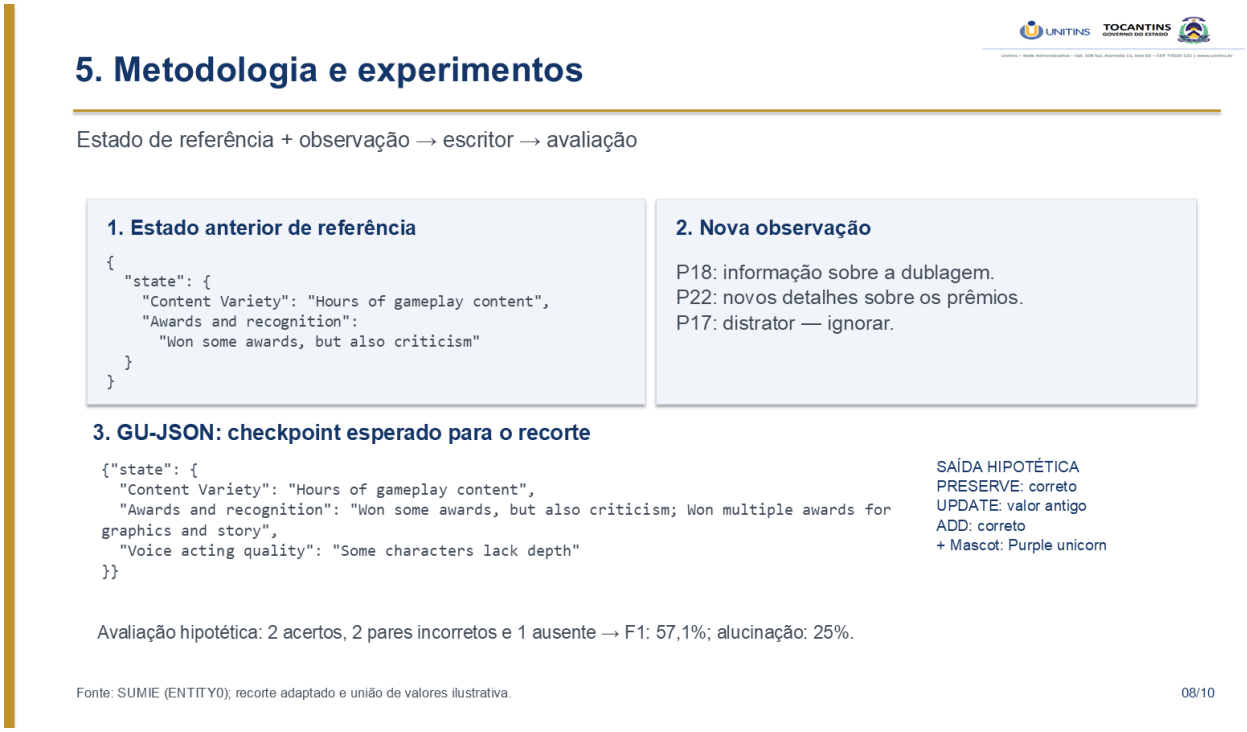
São três objetivos específicos. Primeiro, avaliar a conformidade estrutural, ou seja, se o JSON é válido e segue o schema. Segundo, comparar a fidelidade do estado, com precisão, revocação, F1 e taxa de alucinação. Terceiro, analisar o perfil de erro por tipo de operação.

Slide 7 — até 1:55



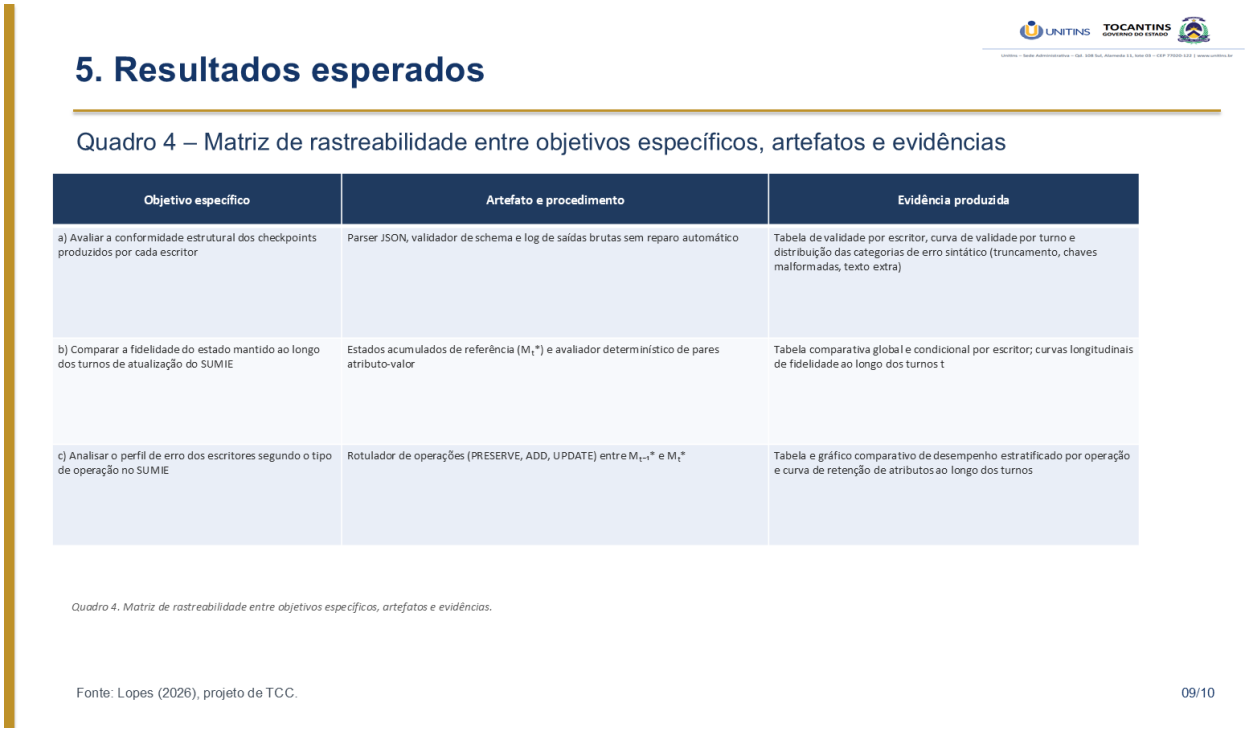
Os dados vêm do SUMIE. Este é um exemplo simplificado: cada parágrafo tem frases numeradas, algumas delas distratoras, e o benchmark anota os atributos e valores sustentados pelas frases. A partir dessas anotações, monto os checkpoints de referência.

Slide 8 — até 2:20



Cada ciclo funciona assim: o modelo recebe o estado de referência e o novo parágrafo, e precisa devolver o JSON atualizado. Neste exemplo, ele deve preservar Content Variety, atualizar a informação sobre prêmios e adicionar a qualidade da dublagem. Nesta saída hipotética, ele não atualiza os prêmios e inventa um mascote. O JSON é válido, mas o F1 cai para 57% e a alucinação chega a 25%.

Slide 9 — até 2:45



5. Resultados esperados

Quadro 4 – Matriz de rastreabilidade entre objetivos específicos, artefatos e evidências

Objetivo específico	Artefato e procedimento	Evidência produzida
a) Avaliar a conformidade estrutural dos checkpoints produzidos por cada escritor	Parser JSON, validador de schema e log de saídas brutas sem reparo automático	Tabela de validade por escritor, curva de validade por turno e distribuição das categorias de erro sintático (truncamento, chaves malformadas, texto extra)
b) Comparar a fidelidade do estado mantido ao longo dos turnos de atualização do SUMIE	Estados acumulados de referência (M_t^*) e avaliador determinístico de pares atributo-valor	Tabela comparativa global e condicional por escritor; curvas longitudinais de fidelidade ao longo dos turnos t
c) Analisar o perfil de erro dos escritores segundo o tipo de operação no SUMIE	Rotulador de operações (PRESERVE, ADD, UPDATE) entre M_{t-1}^* e M_t^*	Tabela e gráfico comparativo de desempenho estratificado por operação e curva de retenção de atributos ao longo dos turnos

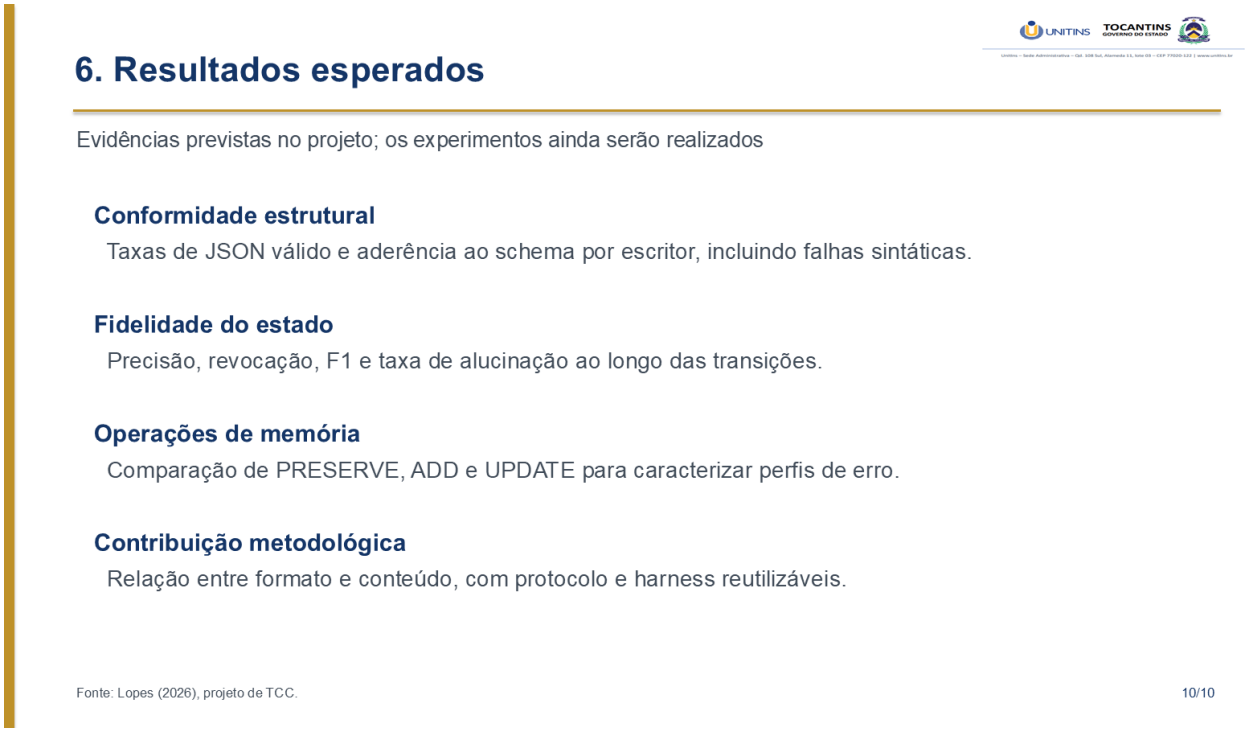
Quadro 4. Matriz de rastreabilidade entre objetivos específicos, artefatos e evidências.

Fonte: Lopes (2026), projeto de TCC.

09/10

O quadro mostra como cada objetivo será medido. No primeiro, o parser e o validador geram as taxas de validade por modelo e por turno. No segundo, comparo os pares atributo–valor com a referência. No terceiro, classifico cada atributo como PRESERVE, ADD ou UPDATE e calculo a acurácia de cada operação, com intervalos de confiança e testes pareados.

Slide 10 — até 3:00



Com isso, espero identificar qual paradigma compacto gera estruturas mais válidas, mantém estados mais fiéis e erra menos em cada operação. O trabalho também deixará um protocolo e um harness reutilizáveis. Obrigado.